

合规智盾 Agent——基于 AI Agent 的金融 合规智能自检与申报系统

国元证券·CFA 商业策划大赛 B 赛道参赛报告 主题：AI Agent 在金融场景的应用
· 场景：合规管理 · 队名：暑假不回家队 队长：韩天翼 队员：彭德东 禹夏航

一、执行摘要

金融行业正经历 AI 从“辅助分析工具”向“智能执行 Agent”的范式跃迁。在投资研究、风险管理、合规管理三大场景中，**合规管理**的痛点尤为突出：法规准则庞杂、人工审查繁重、一线从业者面对抽象准则时“判断门槛高、披露义务易遗漏”。

本方案构建了**合规智盾 Agent**——一个面向 CFA 职业道德合规场景的 AI Agent，以“自主感知—分析决策—任务执行—持续优化”的完整闭环，解决合规管理中的核心难题。员工以自然语言描述自身行为，Agent 自动完成：将口语化描述改写为正式申报语言、识别涉及的 CFA 道德准则条款、评估风险等级、生成披露/审批清单、执行申报任务（生成申报单并真实发送邮件至合规部门）、生成合规自证声明，并引用题库案例佐证判断；合规部门则通过独立的审查视角，对申报进行签名审批并回发审批结果——形成了“员工申报 → 合规审批 → 回执留痕”的双角色协同闭环。

本方案的差异化价值在于：**不是“问答式 AI 工具”，而是“能执行任务的合规 Agent”**——它不仅在边界处识别风险，更通过“申报”与“邮件触达”完成合规闭环，将“被动审查”转变为“主动申报 + 留痕可追溯”。系统以 230 道 CFA 一级道德题库（中英对照）为知识底座，采用 RAG 架构确保结果可解释、有据可依，并针对赛道提出的**五大挑战（模型幻觉、数据安全、可解释性、权限管理、责任边界）**逐一给出工程化应对方案。方案已实现可运行系统并通过 29 项自动化测试，具备直接落地的能力。

二、主题解读与痛点分析

2.1 灵感来源

本方案的灵感，源于一次 CFA 道德科目备考中的真实观察：做完 230 道官方练习题后，我们发现一个耐人寻味的现象——错题并非集中在“记不住准则条文”，而是高度集中在“具体行为场景下如何对号入座”。这让我们意识到一个被忽视的命题：**道德合规的难点，从来不是“知识”，而是“判断”与“行动”**。

与此同时，本次大赛主题“AI Agent 在金融场景的应用”给了我们关键启发：当 AI 从“回答问题”跃迁为“执行任务”，它恰好能补上传统合规工具缺失的一环——不仅能告诉员工“该不该做”，还能替员工“做完该做的”（申报、披露、留痕）。于是，“把 CFA 准则变成合规 Agent”的构想应运而生。

2.2 主题解读与切题程度

B 赛道主题为“AI Agent 在金融场景的应用——投资、风控、合规”，要求方案具备**准确性、可解释性、安全性、实际落地能力**，并体现 Agent 的四大核心能力：**自主感知、分析决策、任务执行、持续优化**。

在三大场景中，合规场景天然契合 Agent 范式：

- **投资研究**依赖主观判断，Agent 价值在于“效率”；
- **风险管理**依赖大量数据，Agent 价值在于“前瞻”；
- **合规管理**的痛点在于**规则可结构化**——CFA 道德准则（Standard I-VII 共 22 条子条款）是明确的、可枚举的规则集合，最适合 Agent 进行“规则解析、制度比对、异常识别、报告生成”。

因此，本方案选择以 **CFA 职业道德合规** 为切入点，构建一个规则驱动、可解释、可执行的合规 Agent。

本方案的切题程度，体现在三层严格对应：其一，**场景对应**——主题三大场景中我们锁定“合规”，而合规场景的 Agent 价值（规则解析、制度比对、异常识别、报告生成）恰好是本系统的四大功能；其二，**能力对应**——主题要求的“自主感知、分析决策、任务执行、持续优化”四大能力逐条落地（详见 3.1）；其三，**标准对应**——准确性、可解释性、安全性、实际落地能力逐条满足（详见第五章）。三层的严格对应，确保了方案始终紧扣主题、不跑题、可衡量。

2.3 合规管理的核心痛点

以本方案所依据的 230 道 CFA 道德题库为例，题目分布揭示了真实痛点：

CFA 一级道德题库模块分布 (230题) - M3 准则应用指南：148 题 (64.3%) - M4 GIPS 业绩标准：32 题 (13.9%) - M1 道德与信任：25 题 (10.9%) - M2 准则框架：22 题 (9.6%) - M5 道德应用：3 题 (1.3%)

其中 **Module 3 (准则 I–VII 应用指南) 独占 148 题 (64.3%)**，且错题高度集中在 Standard III (客户责任) 与 Standard IV (雇主责任) 的案例辨析。这揭示了三个核心痛点：

- 判断门槛高、决策依赖经验：**准则使用大量开放性表述 ("合理努力" "可能损害独立性" "重大信息")，一线员工缺乏结构化工具，判断结果因人、因时而异。
- 披露义务易遗漏：**多项准则 (如 IV(B) 额外报酬、VI(A) 利益冲突) 要求 "事先书面披露 + 取得相关方同意"，但员工常因 "不知道该不该披露、向谁披露、披露什么" 而漏报，事后被认定为违规。
- 申报与留痕割裂：**传统合规工具只 "提示风险"，不 "执行申报"，导致合规动作停留在认知层面，缺乏可追溯的行动闭环。

2.4 破局方向

本方案的破局关键，正是赛道强调的 "**实现 AI 技术能力与金融业务规则、专业知识、风控机制的深度融合**"：将 CFA 道德准则这一专业知识，转化为 Agent 可解析的规则库；将 "申报" 这一风控机制，转化为 Agent 可执行的任务流。

三、产品方案与技术架构

3.1 Agent 四大核心能力的落地映射

本方案严格对标 Agent 范式的四大能力，实现 "感知—决策—执行—优化" 闭环：

Agent能力	系统实现	用户可感知的价值
自主感知	自然语言输入 + 语音识别 + 口语转正式改写 + 9类行为意图分类器（关键词+正则+语义相似度三级识别）	员工用一句话描述行为，Agent 自动"听懂"意图并润色为申报语言
分析决策	风险评级引擎（高/中/低）+ 22 子条款匹配 + RAG 案例检索（Top-5）+ 风险行动强度分级	输出可解释的风险判断、准则依据与行动要求
任务执行	生成申报单 + 一键真实发送邮件 + 合规部签名审批 + 回发审批结果 + 生成合规自证声明（含手写签名与电子印章）	把"认知"转化为"行动"，完成"申报—审批—回执—自证"闭环
持续优化	增量知识库更新 + 结果缓存 + 行为标签倒排索引 + 合规小贴士	新案例可持续沉淀，判断能力随使用增强

流程：员工行为描述 → 自主感知 → 规则分类 → 语义相似度匹配 → 分析决策 → 任务执行 → 持续优化

3.2 Agent 起到了什么作用

在本方案中，Agent 扮演的并非"回答问题的助手"，而是"完成合规动作的执行主体"。其作用可概括为四个方面：

- **对员工**：把"不知道该不该做、向谁披露、披露什么"的困境，转化为"一句话输入 → 有据可依的风险判断 + 可勾选的检查清单 + 现成的申报单"，从"凭感觉"到"有依据"。
- **对合规部门**：把"被动审查"转化为"主动申报 + 留痕可查"，每份申报单带唯一编号与时间戳，可追溯、可审计，审查从"大海捞针"变为"精准核查"。
- **对机构**：把分散的合规知识沉淀为统一知识底座，一线员工随开随用，降低整体合规风险与培训成本。
- **对行业**：证明"规则驱动 + 案例约束 + 任务执行"的 Agent 范式在强监管领域切实可行，为合规科技（RegTech）提供可复制的方法论。

正是"任务执行"这一环，让 Agent 的价值从"给建议"升维到"替办事"，这是本方案区别于一般 AI 问答工具的核心。

3.3 技术架构

- **前端**：PWA (HTML5 + Vanilla JS + 原生 CSS) ， 四视图 (自检/准则速查/历史/合规部) + 申报、自证与审批弹窗，支持语音输入、口语转正式改写、分析引擎切换 (大模型/本地规则)、离线优先。
- **后端**：Python FastAPI + Pydantic v2, RESTful 接口。
- **知识底座**：ChromaDB 向量库 + 离线 TF-IDF/Jieba 嵌入 (零依赖可运行，可选 sentence-transformers 升级) ， 230 道题库结构化存储。
- **检索生成**：RAG 架构——意图分类 → 向量检索 Top-5 案例 → 结构化输出 (LLM 可插拔，未配置时由规则引擎兜底) 。
- **任务执行**：SMTP 邮件发送 (QQ 邮箱，国内无需翻墙) ， 申报单编号生成，自证声明文档生成 (含手写签名板与电子印章) 。

3.4 关键工程决策

1. **RAG 约束而非裸 LLM**：所有判断以检索到的题库案例为依据，从架构上抑制幻觉，确保"结论有据可依"。
2. **规则引擎 + 语义检索双通道**：兼顾低延迟与高召回，且不依赖昂贵 API 即可运行，符合"安全可靠可落地"要求。
3. **离线优先架构**：核心判断逻辑在浏览器端本地运行，数据不出本机，契合金融机构对数据安全性与网络隔离的严苛要求。

3.5 多智能体协同 (已落地)

赛道技术底座中特别提到"多智能体协同"，本方案已落地四个 Agent 中的三个，形成"员工自检 → 合规审查"的双角色协同：

- **自检 Agent** (已实现)：面向员工，负责意图感知与风险识别，输出风险评级、准则匹配与行动要求；
- **申报 Agent** (已实现)：负责口语转正式改写、生成合规申报文件与邮件触达；
- **审查 Agent** (已实现)：面向合规部门，提供独立的审批视角——查看全部申报、签名审批 (通过/驳回)、回发审批结果邮件；
- **审计 Agent** (扩展)：负责留痕归档、生成合规审计报告，是后续规模化的方向。

三个已实现的 Agent 各司其职、通过统一的知识库与申报数据协同，完整对应了赛道"自主感知、分析决策、任务执行、持续优化"的能力分层，也完整覆盖了"投资、风

控、合规"场景中合规条线的员工端与合规部门端两条工作流。这一从"单一工具"到"合规 workflows 智能编排"的演进，是本方案对"多智能体协同"这一技术底座要求的直接落地。

四、数据基础与实证分析

4.1 数据来源与结构化

项目以 CFA 一级道德题库（230 题，中英对照，含答案解析与"做题方法"）为种子数据，完成从非结构化 PDF 到结构化知识库的全流程数据工程，提取并增强字段包括：题号、模块、准则代码、中英情景、行为标签、风险等级、必做动作、答案解析。

维度	数值
题目总数	230
准则子条款覆盖	22 条 (I(A)–VII(B)) 全覆盖
含明确准则代码的合规案例	161 (用于检索)
风险等级分布	高 71 / 中 71 / 低 88
行为类别	9 类 (收礼/兼职/离职/交易/报酬/研报/内幕/冲突/不当行为)

4.2 实证验证

系统经 29 项自动化测试全部通过，覆盖分类器单元测试、RAG 引擎测试、API 测试。典型实例：

- 例 1（收礼/差旅）**：输入"客户邀请我去打高尔夫，还主动提出承担我出差的机票和酒店费用"→ 判定**高风险**，命中 I(B)/IV(B)/VI(A)，引用案例 M3-Q30（会议差旅招待），生成"拒绝可能损害独立客观性的礼品""向雇主书面披露"等清单项。
- 例 2（额外报酬）**：输入"客户在公司薪酬之外额外付我一笔奖金"→ 命中 IV(B)/VI(C)，引用 M3-Q12，正确提示"接受前须书面披露并取得相关方书面同意"而非一律拒绝。
- 例 3（边界情况）**：对无关输入（如"今天天气不错"）系统返回 `uncertain`，未产生高置信度误报，验证了可解释性与安全性设计。

4.3 数据处理规范性

- 数据来源明确（CFA Institute 官方练习题整理，权威可信）；
- 多准则题目全量列出、干扰项准则已排除（仅保留"正确"部分的准则）；
- 风险等级由准则条款映射 + 案例加权综合判定，逻辑可追溯。

4.4 一个完整的合规闭环实例

为说明 Agent 的"执行"能力，举一个端到端实例：员工输入"客户邀请我去打高尔夫，还主动提出承担我出差的机票和酒店费用"。

1. **感知**：Agent 识别行为类别为"收礼招待"；
2. **决策**：判定风险为"高"，命中 I(B) 独立性与客观性、IV(B) 额外报酬、VI(A) 利益冲突三条准则，检索到 M3-Q30 会议差旅招待案例作为依据；
3. **执行**：生成一份带唯一编号（如 SB-20260824-XXXX）的申报单，通过 SMTP 将申报邮件真实发送至合规部门邮箱；
4. **留痕**：申报记录存入本地，可导出 PDF，形成可追溯的合规证据链。

这一实例证明，本方案并非停留在"给出建议"的认知层面，而是真正把合规动作执行到了"邮件触达、留痕可查"的行动层面——这正是"AI Agent"区别于"AI 问答"的本质。

五、五大挑战的应对方案

赛道明确提出"模型幻觉、数据安全、结果可解释性、权限管理、责任边界"五大现实挑战。本方案逐一给出工程化应对：

挑战	本方案的应对
模型幻觉	RAG 架构以题库案例为约束上下文；温度参数 0.3 保证输出稳定；JSON 解析失败自动回退规则引擎；高风险必填披露字段
数据安全	支持纯本地离线运行（行为描述不出本机）；历史记录仅存本地 IndexedDB；支持机构私有化部署；申报邮件经本地 SMTP 直发，不经过第三方
结果可解释性	每个风险判断均附带"涉及的准则条款 + 引用的题库案例"，评分由规则映射可追溯；不输出"黑箱"结论

挑战	本方案的应对
权限管理	申报流程为"员工提交 → 合规部门签名审批"的留痕闭环；申报单带唯一编号与时间戳；审批需二次确认与签名，审批结果回发邮件留痕
责任边界	Agent 定位为"辅助决策工具"，输出明确标注参考性质；高风险场景强制引导向合规部门报备；人工确认后行动才生效

这些应对并非纸面承诺，而是已在系统中落地实现：例如"数据安全"由离线 PWA 架构直接保证，"可解释性"由案例引用直接呈现，"责任边界"由申报留痕与披露草稿直接实现。

六、改进过程与迭代

本方案并非一蹴而就，而是经历了一个"从工具到 Agent"的持续迭代过程——这一过程本身，也印证了 Agent 的"持续优化"能力：

- 1. **第一阶段——数据筑基**：将 230 道题库从 PDF 结构化提取，构建知识底座与行为标签倒排索引；
- 2. **第二阶段——感知与决策**：实现 9 类行为意图分类与风险评级，形成基础"自检"能力；
- 3. **第三阶段——可解释增强**：引入 RAG 案例检索，让每个判断附带题库案例依据；
- 4. **第四阶段——从工具到 Agent 的关键跃迁**：加入"任务执行"——自动生成申报单、一键发送邮件，系统由此具备 Agent 的"执行"属性；
- 5. **第五阶段——完善闭环**：增加风险拦截、合规自证声明、口语转正式改写与风险行动强度分级，形成"识别—拦截—申报—自证"完整链路；
- 6. **第六阶段——落地优化**：将邮件发送从依赖国外第三方服务改为国内 QQ 邮箱 SMTP（确保无外网依赖、真正可落地），并完成界面优化与局域网演示方案；
- 7. **第七阶段——多智能体协同**：上线合规部审查视角，实现"员工申报 → 合规签名审批 → 回执邮件"的双角色协同闭环，直接落地赛道的"多智能体协同"与"权限管理"要求。

这一迭代路径清晰展示：Agent 的"持续优化"并非口号，而是贯穿研发全程的实际动作——每轮改进都让系统离"可解释、可执行、可落地"更近一步。

七、使用价值与可推广性

使用价值（紧扣“实际落地能力”）：

- **一线员工**：行动前即时决策支持，从“凭经验猜”到“有依据判”，降低无意违规风险；
- **合规部门**：申报留痕可追溯、编号可查，审查降本增效；
- **机构**：合规知识沉淀为统一底座，合规文化落地，减少整体合规成本。

可推广性（紧扣“持续优化”与规模化）：

- **横向扩展**：方法论可从 CFA 道德准则复制到软美元、GIPS、反洗钱等更广合规域；
- **纵向复用**：同一 Agent 架构可复用于投资研究（自主获取分析）与风险管理（动态识别预警）场景；
- **多智能体协同**：自检、申报、审查、审计四类 Agent 分工协作，向合规工作流的智能编排演进；
- **跨行业迁移**：医药、法律、证券等强监管行业，均可复用“规则驱动 + 案例约束 + 任务执行”的范式。

八、商业模式与落地路径

6.1 商业模式

- **目标用户**：CFA 考生与持证人、投资机构合规部门、金融培训机构学员、财经专业学生。
- **产品分层**：个人版（本地离线自检，免费）→ 团队版（机构内网部署、历史审计、批量分析，订阅收费）→ 定制版（接入机构内部合规规则与语料，项目制收费）。
- **收入来源**：企业订阅（SaaS）、私有化部署授权、准则/题库内容授权、合规培训增值服务。

6.2 落地路径

第一阶段：以现有可运行系统（含 230 题知识库、9 类行为分类、双角色审批协同、PWA 前端、邮件申报）完成功能验证与用户反馈收集。**第二阶段：**面向投资机构做内网私有化部署试点，验证数据安全与离线可用性。**第三阶段：**接入商用大模型（DeepSeek/通义），扩充行业语料（软美元、GIPS、反洗钱等），从 CFA 道德准则扩展至更广合规域。**第四阶段：**形成标准化 SaaS + 私有化两条产品线，规模化获客。

6.3 团队分工

成员	角色	主要贡献
韩天翼（队长）	项目统筹与产品设计	方案整体规划、技术架构设计、核心功能开发与部署上线
彭德东	数据工程与行业调研	CFA 题库结构化处理、行业痛点调研、数据实证分析
禹夏航	测试与展示支持	系统功能测试、演示脚本与答辩材料准备、现场演示支持

团队分工明确、各司其职，三位成员全程参与、均有建树：队长统筹全局并主导研发，两位队员分别在数据工程与测试展示环节发挥关键作用，体现了良好的团队协作精神。

九、结论

本方案以 CFA 职业道德合规为切入点，构建了一个具备"自主感知—分析决策—任务执行—持续优化"完整闭环的合规 AI Agent。其核心价值在于：**将抽象的职业道德准则，转化为一线员工可即时使用的决策支持与行动执行工具**——用 RAG 保证"结论有据可依"（可解释），用规则兜底保证"任何环境可用"（安全），用申报与邮件保证"行动可执行、可追溯"（落地）。

在评分标准维度上，方案具备：**主题创新性**（Agent 范式下沉到个人合规行为辅助，而非传统问答工具）、**研究方法**（规则+语义双通道、三级流水线、RAG 约束）、**数据处理**（230 题全结构化、22 子条款全覆盖、三级测试验证）、**结论贡献**（可直接落地的系统与可复用的合规 Agent 构建方法论）。本方案已实现自检、申报、审查三类

Agent 的协同，未来随准则库扩充与审计 Agent 的补全，该方案有望成为金融职业道德数字化治理的基础设施级工具。